Pós -graduação Ciência de Dados — PUC Rio Sprint 3 — Engenharia de Dados

Aluno: Frederico Araújo Soares

Objetivo

Este trabalho tem como resultado, a criação de algumas tabelas referentes a dados de chuva/precipitação da cidade de Goiânia – GO.

O Pipeline irá ser executado para carregar os dados tratados em algumas tabelas no serviço da cloud do Google, serviço chamado BigQuery.

O objetivo deste trabalho é finalizar o pipeline para disponibilizar os dados em algumas consultas para responder as seguintes perguntas:

- É possível identificar eventos extremos com picos de precipitação, temperaturas ou rajadas de ventos?
- Investigar como a radiação solar influencia outras variáveis como tempertatura e umidade.

Detalle dos dados

O dados serão obtidos no sítio eletrônico do INMET (https://portal.inmet.gov.br/dadoshistoricos). Em seguida será realizado um tratamento para obter somente os dados de Goiânia.

Fluxo de execução do Pipeline

Será executado um Notebook dentro do BigQuery chamado "mvp3-engenharia-dados-coleta-dados.ipynb". Este notebook está presente nos arquivos aqui deste repositório github. Os seguintes passos serão executados:

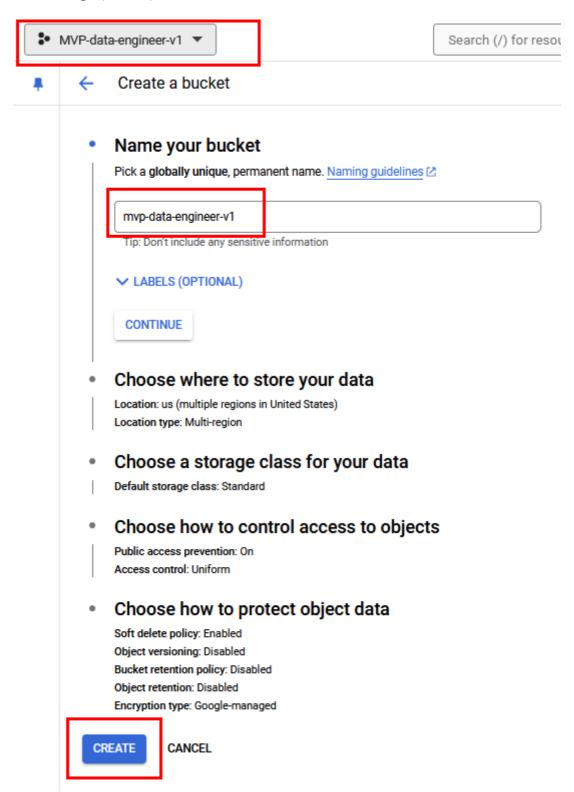
- 1. Coleta dos dados
- 2. Extração e seleção do csv de Goiânia
- 3. Tratamento para dados faltantes
- 4. Upload para o Google Cloud Storage (bucket) dos dados atuais processados e histórico dos dados executados.
- 5. Carregamento dos dados nas tabelas do BigQuery
- 6. Apresentação dos dados no BigQuery e Power BI Desktop

Configuração da Infraestrutura

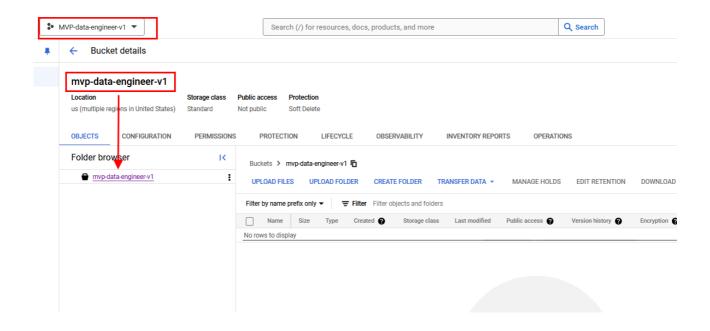
Criação do Projeto

Primeiramente é necessário criar o projeto no Google Cloud. No caso criei um projeto chamado MVP-data-engineer-v1.

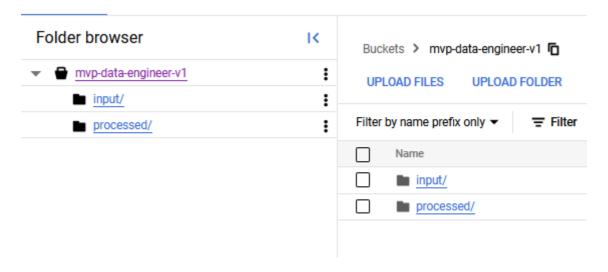
Criação do storage (bucket):



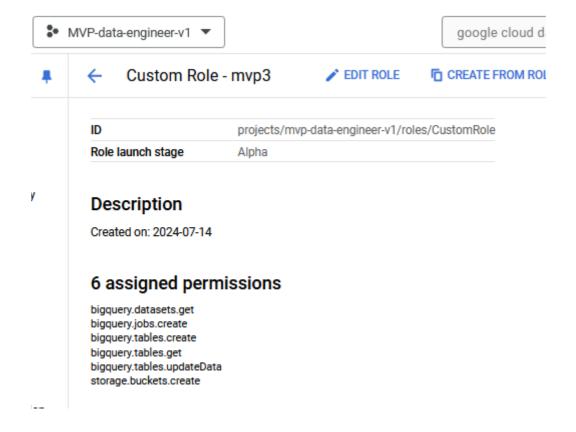
Detalhes do bucket:



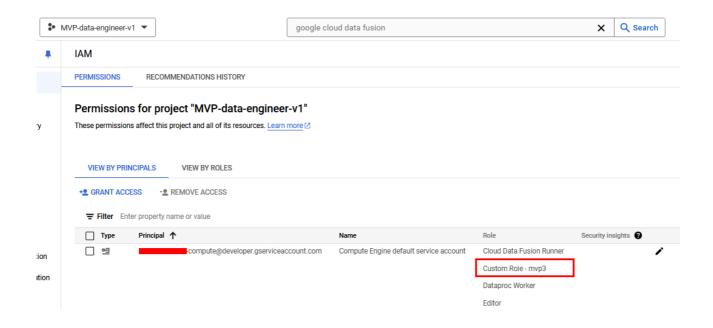
Apresentação dos diretórios



Criado um Custom Role com as seguintes permissões:



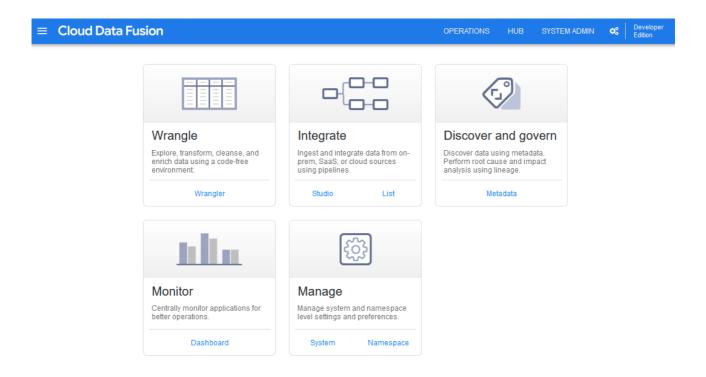
No usuário do projeto, adicionei o Role criado:



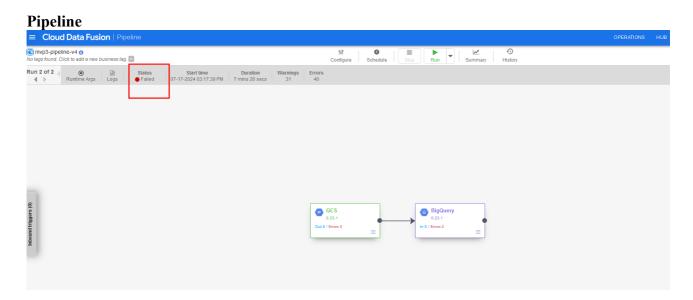
Pipeline Google Cloud Data Fusion

Foi criado inicialmente um pipeline com o Fusion, porém não consegui identificar a tempo um erro de transformação dos dados do CSV para a tabela do BigQuery.

Após criar a instância do Fusion, clique para visualizar a instancia:



Foi criado o pipleline simples do bucket para a tabela no BigQuery, porém, apresentou erros de formatação. Como o prazo final já estava perto, preferi criar o pipeline com o notebook. A seguir as telas do pipeline e os erros:



Erros



■ Cloud Data Fusion

Level - Message

Time

App Name: mvp3-pipeline-v4 Program Name: DataPipeline-Workflow Status: FAILED Start Time: 07-17-2024 03:17:39 PM End Time: 07-17-2024 03:25:05 PM

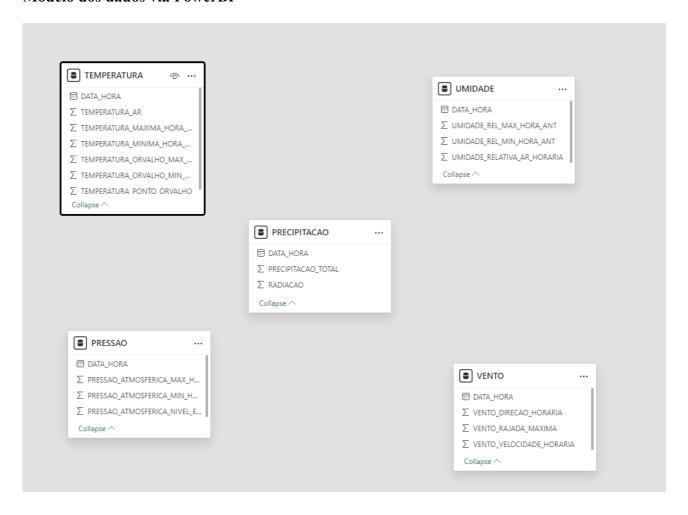
org:apacne-spairt-scheduler.bAG5cheduler.abont5tage(bAG5cheduler.scalat.ztos) at org.apacne-spairt-scheduler.bAG5cheduler.salionalier.ask5et-alled5t(bAG5cheduler.scalat.tros) at org.apacne-spairt-scheduler.bAG5cheduler.scalat.tros) at org.apacne-spairt-scheduler.bAG5cheduler.scalat.tros)
\$anonfun\$handleTaskSetFailed\$1\$adapted(DAGScheduler.scala:1189) at scala.Option.foreach(Option.scala:407) at org.apache.spark.scheduler.DAGScheduler.handleTaskSetFailed(DAGScheduler.scala:1189)
org apache. spark. scheduler.DAGSchedulerEventProcessLoop.doOnReceive(DAGScheduler.scala.2913) at org. apache. spark. scheduler.DAGSchedulerEventProcessLoop.onReceive(DAGScheduler.scala.2855) ε
org. apache. spark. scheduler.DAGScheduler.Event.ProcessLoop onReceive(DAGScheduler.scala-2844) at org. apache. spark. util. EventLoop\$\$anon\$1.run(EventLoop.scala-49) at org. apache. spark. scheduler.DAGSc
org apache.spark.SparkContext.runJob(SparkContext.scala:2293) at org apache.spark.SparkContext.runJob(Spar
org apache. spark.internal.io. SparkHadoopWriter\$. write(SparkHadoopWriters.cala:83) 30 more Caused by: org.apache.spark.SparkException: Task failed while writing rows at org.apache.spark.internal.io. Spa
org. apache. spark. internal io. SparkHadoopWriter\$. \$anonfun\$write\$1(SparkHadoopWriter s.cala.88) at org. apache. spark. scheduler. ResultTask. runTask(ResultTask. scala.90) at org. apache. spark. scheduler. Task. ru

\$anonfun\$run\$3(Executor.scala:548) at org.apache.spark.util.Utils\$.tryWithSafeFinally(Utils.scala:1505) at org.apache.spark.executor.Executor\$TaskRunner.run(Executor.scala:551) at java.base/java.util.concur java util.concurrent.ThreadPoolExecutor\$Worker.run(ThreadPoolExecutor.java:628) at java.base/java.lang.Thread.run(Thread.java:829) Caused by: java.lang.NumberFormatException: For input string: *17040996(java lang NumberFormatException forinputString(NumberFormatException java 65) at java.base/java lang Long parseLong(Long java 692) at java.base/java lang Long parseLong(Long java 817) at io cdap.cdap.ap at io.cdap.cdap.api.data.format.StructuredRecord\$Builder.convertAndSet(StructuredRecord.java.630) at io.cdap.cdap.format.StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConverter.handleFieldConversion(StructuredRecordStringConvers io.cdap.plugin.format.delimited.common.DelimitedStructuredRecordStringConverter.parseAndSetFieldValue(DelimitedStructuredRecordStringConverter.java:46) at

io.cdap.plugin.format.delimited.input.PathTrackingDelimitedinputFormat\$1.nextKeyValue(PathTrackingDelimitedInputFormat,java:95) at io.cdap.plugin.format.input.PathTrackingInputFormat\$TrackingRecordReac org apache hadoop mapreduce lib input CombineFileRecordReaderWrapper.nextKeyValue(CombineFileRecordReaderWrapper.java.90) at org apache hadoop mapreduce lib input CombineFileRecordReader.next org. apache. spark. rdd. NewHadoopRDD\$\$anon\$1. hasNext(NewHadoopRDD. scala: 251) at org apache. spark. InterruptibleIterator hasNext(InterruptibleIterator.scala: 37) at scala collection. Iterator\$\$anon\$11. hasNex \$anon\$11.hasNext(Iterator.scala.491) at scala.collection.Iterator\$\$anon\$11.hasNext(Iterator.scala.491) at org.apache.spark.internal.io.SparkHadoopWriter\$.\$anonfun\$executeTask\$1(\$parkHadoopWriter.scala:1 org.apache.spark.util.Utils\$.tryWithSafeFinallyAndFailureCallbacks(Utils.scala.1539) at org.apache.spark.internal.io.SparkHadoopWriter\$.executeTask(SparkHadoopWriter.scala.135) ... 9 more

07/17/2024 15:25:04	ERROR	Spark Program 'phase-1' failed.
07/17/2024 15:25:04	ERROR	Spark program 'phase-1' failed with error: Application application_1721240363123_0002 finished with failed status. Please check the system logs for more details.
07/17/2024 15:25:04	ERROR	Pipeline 'mvp3-pipeline-v4' failed.
07/17/2024 15:25:05	ERROR	Workflow service 'workflow default.mxp3-pipeline-v4. DataPipelineWorkflow.da27e576-4468-11ef-b93e-b655d335fbe7' failed.
07/17/2024 15:25:05	ERROR	Program DataPipelineWorkflow execution failed.
07/17/2024 15:25:10	ERROR	Dataproc job failed with the status details: Job failed with message [java.lang.reflect.InvocationTargetException: null]. Additional details can be found at: https://console.cloud.google.com/dataproc/jobs/default_n
		project=mmp-data-engineer+v1®ion=us-west1 gcloud dataproc jobs wait 'default_mmp3-pipeline-v4_DataPipelineWorkflow_da27e576-4468-11ef-b93e-b655d335fibe7region 'us-west1'project 'mmp-data-enginee
		west1-833389999536-aastuwp5/google-cloud-dataproc-metainfo/78787589-0d30-4ba1-89d2-c52a4872a2a8/jobs/default_mvp3-pipeline-v4_DataPipelineWorldlow_da27e576-4468-11ef-b93e-b655d335fbe7/gs://dat
		metainfo/78787589-0d30-4ba1-89d2-c52a4872a2a8/jobs/default_mvp3-pipeline-v4_DataPipelineWorkflow_da27e576-4468-11ef-b93e-b655d335fbe7/driveroutput.*

Modelo dos dados via PowerBI

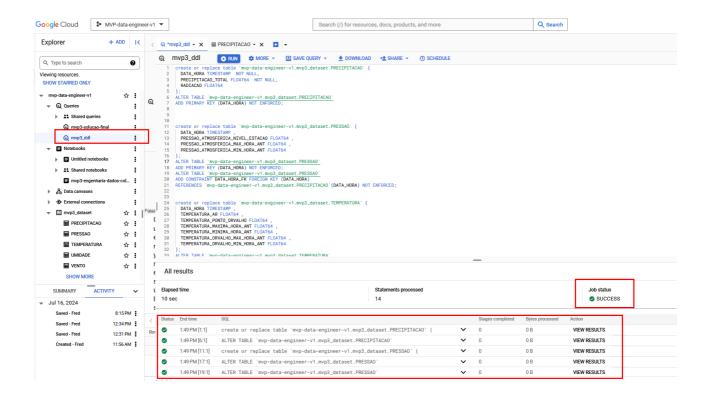


Criação no BigQuery das Tabelas

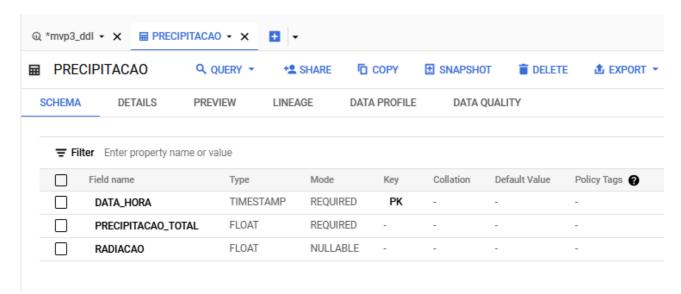
O arquivo mvp3 ddl.sql possui o sql de criação das tabelas.

Aqui é importante ressaltar as limitações do BigQuery. As chaves primárias e estrangeiras são "not enforced" de acordo com a documentação:

https://cloud.google.com/bigquery/docs/information-schema-table-constraints#limitations



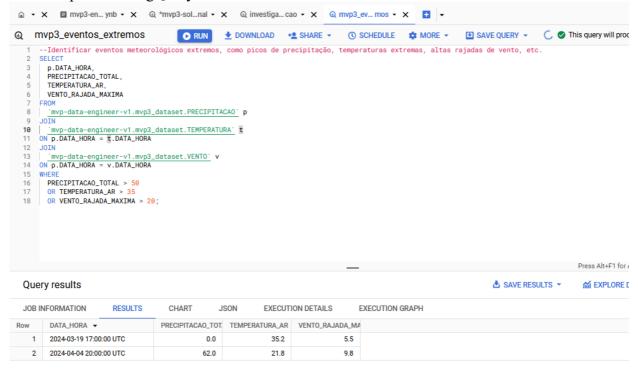
Exemplo da Tabela PRECIPITACAO:



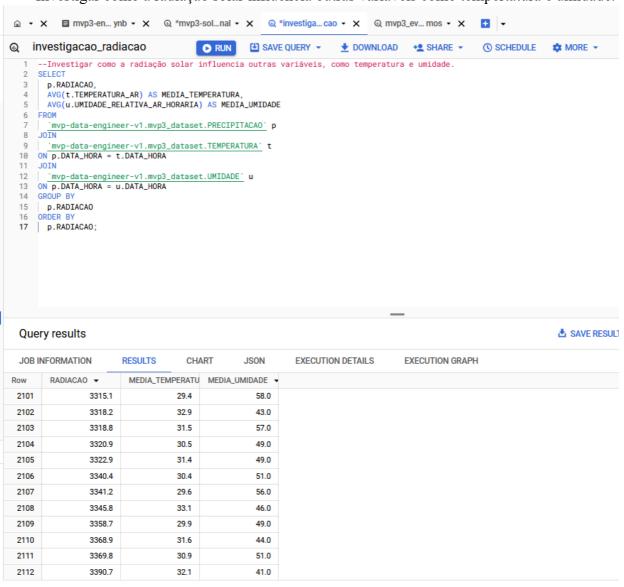
SOLUÇÃO: Analisando se as perguntas dos objetivos foram atendidas

• É possível identificar eventos extremos com picos de precipitação, temperaturas ou rajadas de ventos?

Resposta via BigQuery:



• Investigar como a radiação solar influencia outras variáveis como tempertatura e umidade.



Dados Apresentados via Power BI acessando o BigQuery

